





条件随机场

七月算法 邹博



2015年12月13日

网络模型比较HMM/MEMM/CRF/RVM



分析对图像像素间建立贝叶斯网络

□ 考察 X_8 的马尔科夫毯(Markov blanket)



无向图模型

- 有向图模型，又称作贝叶斯网络(Directed Graphical Models, **DGM**, Bayesian Network)
 - 事实上，在有些情况下，强制对某些结点之间的边增加方向是不合适的。
- 使用没有方向的无向边，形成了无向图模型(Undirected Graphical Model, **UGM**), 又称马尔科夫随机场或马尔科夫网络(Markov Random Field, **MRF** or Markov network)
 - 注：概率有向图模型/概率无向图模型



条件随机场

□ 设 $X=(X_1, X_2 \dots X_n)$ 和 $Y=(Y_1, Y_2 \dots Y_m)$ 都是联合随机变量，若随机变量 Y 构成一个无向图 $G=(V, E)$ 表示的马尔科夫随机场(MRF)，则条件概率分布 $P(Y|X)$ 称为条件随机场(Conditional Random Field, CRF)

■ X 称为输入变量、观测序列

■ Y 称为输出序列、标记序列、状态序列

■ 大量文献将MRF和CRF混用，包括经典著作。

■ 一般而言，MRF是关于隐变量(状态变量、标记变量)的图模型，而给定观测变量后考察隐变量的条件概率，即为CRF。


■ 但这种混用，类似较真总理和周恩来的区别。

□ 有时候没必要区分的那么严格


□ 混用的原因：在计算 $P(Y|X)$ 时需要将 X 也纳入MRF中一起考虑



DGM转换成UGM




Bayesian network




Markov random field




DGM转换成UGM





$4 \perp 5 | 2$



条件独立的破坏



□ 靠考察是否有 $A \perp B|C$ ，则计算U的祖先图
(ancestral graph): $U = A \cup B \cup C$



$$4 \perp 5 | 2$$



MRF的性质

□ 成对马尔科夫性


- pairwise Markov property

□ 局部马尔科夫性

- local Markov property

□ 全局马尔科夫性

- global Markov property



Pairwise $1 \perp 7 | \text{rest}$

Local $1 \perp \text{rest} | 2, 3$

Global $1, 2 \perp 6, 7 | 3, 4, 5$


□ 记号：随机变量 $Y = (Y_1, Y_2, \dots, Y_m)$ 构成无向图

$G = (V, E)$ ，结点(集) v 对应的(联合)随机变量是 Y_v 。



成对马尔科夫性

- 设 u 和 v 是无向图 G 中任意两个没有边直接连接的结点， G 中其他结点的集合记做 O ；则在给定随机变量 Y_o 的条件下，随机变量 Y_u 和 Y_v 条件独立。
- 即： $P(Y_u, Y_v | Y_o) = P(Y_u | Y_o) * P(Y_v | Y_o)$




$1 \perp 7 | \text{rest}$



局部马尔科夫性

- 设 v 是无向图 G 中任意一个结点， W 是与 v 有边相连的所有结点， G 中其他结点记做 O ；则在给定随机变量 Y_W 的条件下，随机变量 Y_v 和 Y_O 条件独立。
- 即： $P(Y_v, Y_O | Y_W) = P(Y_v | Y_W) * P(Y_O | Y_W)$




$1 \perp \text{rest} | 2, 3$



全局马尔科夫性

□ 设结点集合A, B是在无向图G中被结点集合C分开的任意结点集合, 则在给定随机变量 Y_C 的条件下, 随机变量 Y_A 和 Y_B 条件独立。



□ 即: $P(Y_A, Y_B | Y_C) = P(Y_A | Y_C) * P(Y_B | Y_C)$



$1, 2 \perp 6, 7 | 3, 4, 5$



三个性质的等价性



- 根据全局马尔科夫性，能够得到局部马尔科夫性；
- 根据局部马尔科夫性，能够得到成对马尔科夫性；
- 根据成对马尔科夫性，能够得到全局马尔科夫性；

- 事实上，这个性质对MRF具有**决定性**作用：
 - 满足这三个性质(或其一)的无向图，称为MRF。



贝叶斯网络与条件随机场

- 在研究贝叶斯网络的过程中，重点考察了LDA模型、HMM模型，使用Markov模型进行了MCMC；
- 在条件随机场的研究学习中，将重点考察线性链MRF(LC-CRF, Linear Chain Conditional Random Field)




团和最大团

□ 无向图G中的某个子图S，若S中任何两个结点均有边，则S称作G的团(Clique)。

■ 若C是G的一个团，并且不能再加入任何一个G的结点使其称为团，则C称作G的最大团(Maximal Clique)。


□ 团： $\{1,2\}$, $\{1,3\}$, $\{2,3\}$, $\{2,4\}$, $\{3,4\}$, $\{3,5\}$, $\{1,2,3\}$, $\{2,3,4\}$

□ 最大团： $\{1,2,3\}$, $\{2,3,4\}$, $\{3,5\}$



Hammersley-Clifford定理


□ UGM的联合分布可以表示成最大团上的随机变量的函数的乘积的形式；这个操作叫做UGM的因子分解 (Factorization)。



$$p(\mathbf{y}|\boldsymbol{\theta}) = \frac{1}{Z(\boldsymbol{\theta})} \psi_{123}(y_1, y_2, y_3) \psi_{234}(y_2, y_3, y_4) \psi_{35}(y_3, y_5)$$




Hammersley-Clifford定理



□ UGM的联合概率分布 $P(Y)$ 可以表示成如下形式:

$$P(Y) = \frac{1}{Z} \prod_c \psi_c(Y_c)$$

$$Z = \sum_Y \prod_c \psi_c(Y_c)$$



□ 其中, C 是 G 的最大团, $\psi_c(Y_c)$ 是 C 上定义的严格正函数, 被称作势函数(Potential Function)。因子分解是在UGM所有的最大团上进行的。




线性链条件随机场

- 设 $X=(X_1, X_2 \dots X_n)$ 和 $Y=(Y_1, Y_2 \dots Y_m)$ 都是联合随机变量，若随机变量 Y 构成一个无向图 $G=(V, E)$ 表示的马尔科夫随机场(MRF)，则条件概率分布 $P(Y|X)$ 称为条件随机场(Conditional Random Field, CRF)
- 即：
$$P(Y_v|X, Y_w, w \neq v) = P(Y_v|X, Y_w, w \in v)$$
- 其中， $w \in v$ 表示与结点 v 相连的所有结点 w
- 一种重要而特殊的CRF是线性链条件随机场(Linear Chain Conditional Random Field)，可用于标注等问题。这时，条件概率 $P(Y|X)$ 中， Y 表示标记序列(或称状态序列)， X 是需要标注的观测序列。



线性链条件随机场

□ 线性链条件随机场的无向图模型



$$\mathbf{X} = X_1, \dots, X_{n-1}, X_n$$



线性链条件随机场的定义

- 设 $X=(X_1, X_2 \dots X_n)$ 和 $Y=(Y_1, Y_2 \dots Y_n)$ 均为线性链表示的随机变量序列，若在给定随机变量序列 X 的条件下，随机变量序列 Y 的条件概率分布 $P(Y|X)$ 构成条件随机场，即满足马尔科夫性

$$P(Y_i | X, Y_1, Y_2 \dots Y_n) = P(Y_i | X, Y_{i-1}, Y_{i+1})$$

- 则称 $P(Y|X)$ 为 **线性链条件随机场**。在标注问题中， X 表示输入序列或称观测序列， Y 表述对应的输出标记序列或称状态序列。



线性链条件随机场的参数化形式

- 设 $P(Y|X)$ 为线性链条件随机场，则在随机变量 X 取值为 x 的条件下，随机变量 Y 取值为 y 的条件概率有以下形式：

$$P(y|x) = \frac{1}{Z(x)} \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right)$$

□ 其中， $Z(x) = \sum_y \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right)$

- 特征函数： $t_k(y_{i-1}, y_i, x, i)$ 、 $s_l(y_i, x, i)$
- 特征函数对应的权值： λ_k 、 μ_l
- $Z(x)$ 为规范化因子，保证 $P(Y|X)$ 为概率分布。



参数说明

- t_k 是定义在边上的特征函数，称为转移特征，依赖于当前和前一个位置；
- s_l 是定义在结点上的特征函数，称为状态特征，依赖于当前位置；
- t_k 和 s_l 都依赖于位置，是局部特征函数；
- 通常， t_k 和 s_l 取值为1或者0；满足特征条件时取1，否则取0；
- CRF完全由特征函数 t_k 、 s_l 和对应的权值 $\lambda_k \mu_l$ 确定。
- 线性链条件随机场模型属于对数线性模型。



条件随机场举例

[PRP He] [VBZ reckons] [DT the] [JJ current] [NN account] [NN deficit] [MD will] [VB narrow] [TO to] [RB only] [# #] [CD 1.8] [CD billion] [IN in] [NNP September] [. .]

- NN、NNS、NNP、NNPS、PRP、DT、JJ分别代表普通名词单数形式、普通名词复数形式、专有名词单数形式、专有名词复数形式、代词、限定词、形容词

$$b(\mathbf{x}, i) = \begin{cases} 1 & \text{if the observation at position } i \text{ is the word "September"} \\ 0 & \text{otherwise.} \end{cases}$$

$$t_j(y_{i-1}, y_i, \mathbf{x}, i) = \begin{cases} b(\mathbf{x}, i) & \text{if } y_{i-1} = \text{IN and } y_i = \text{NNP} \\ 0 & \text{otherwise.} \end{cases}$$



条件随机场举例

□ 设有一标注问题：输入观测序列为 $X=(X_1, X_2, X_3)$ ，输出标记序列为 $Y=(Y_1, Y_2, Y_3)$ ， Y_1, Y_2, Y_3 的取值范围为 $\{1, 2\}$ 。

□ 对于第一条连接边，假设特征和权值如下：

$$t_1 = t_1(y_{i-1} = 1, y_i = 2, x, i), \quad i = 2, 3, \quad \lambda_1 = 1$$

□ 其含义是对于给出条件的式子，值为1；否则，值为0，即：

$$t_1(y_{i-1}, y_i, x, i) = \begin{cases} 1 & \text{当 } y_{i-1} = 1, y_i = 2, i = 2, 3 \\ 0 & \text{其他} \end{cases}$$



条件随机场举例

- ☐ $t1=t1(y1=1,y2=2,x,2)$ $\lambda_1=1$
- ☐ $t1=t1(y2=1,y3=1,x,3)$ $\lambda_1=1$
- ☐ $t2=t2(y1=1,y2=1,x,2)$ $\lambda_2=0.5$
- ☐ $t3=t3(y2=2,y3=1,x,3)$ $\lambda_3=1$
- ☐ $t4=t4(y1=2,y2=1,x,2)$ $\lambda_4=1$
- ☐ $t5=t5(y2=2,y3=2,x,3)$ $\lambda_5=0.2$
- ☐ $s1=s1(y1=1,x,1)$ $\mu_1=1$
- ☐ $s2=s2(y2=2,x,i)$ $\mu_2=0.5$
- ☐ $s3=s3(y1=1,x,i)$ $\mu_3=0.8$
- ☐ $s4=s4(y3=2,x,i)$ $\mu_4=0.5$



条件随机场举例

□ 则标记序列为 $y=(1,2,2)$ 的非规范化概率为：

$$\begin{aligned} P(y|x) &= \frac{1}{Z(x)} \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right) \\ &\propto \exp \left(\sum_{k=1}^5 \lambda_k \sum_{i=2}^3 t_k(y_{i-1}, y_i, x, i) + \sum_{l=1}^4 \mu_l \sum_{i=1}^3 s_l(y_i, x, i) \right) \\ &= \exp(3.2) \end{aligned}$$



使用统一的函数记号表达特征

- 为方便起见，将转移特征和状态特征及其权值同统一的符号表示。
- 设有 K_1 个转移特征， K_2 个状态特征， $K=K_1+K_2$ ，则

$$f_k(y_{i-1}, y_i, x, i) = \begin{cases} t_k(y_{i-1}, y_i, x, i) & k = 1, 2, \dots, K_1 \\ s_l(y_i, x, i) & k = K_1 + l; l = 1, 2, \dots, K_2 \end{cases}$$

- 在各个位置求和：

$$f_k(y, x) = \sum_{i=1}^n f_k(y_{i-1}, y_i, x, i), \quad k = 1, 2, \dots, K$$



CRF的简化形式

□ 用 w 表示统一的权值:

$$w = \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_K \end{pmatrix}$$

□ 则CRF可表示成:

$$P(y|x) = \frac{1}{Z(x)} \exp\left(\sum_{k=1}^K w_k f_k(y, x)\right)$$

$$Z(x) = \sum_y \exp\left(\sum_{k=1}^K w_k f_k(y, x)\right)$$



CRF的简化形式

□ 以 $F(y,x)$ 表示全局特征向量:

$$F(y,x) = \begin{pmatrix} f_1(y,x) \\ f_2(y,x) \\ \vdots \\ f_K(y,x) \end{pmatrix}$$

□ 则CRF可以写成向量内积的形式:

$$P(y|x) = \frac{\exp(w^T F(y,x))}{Z(x)}$$

$$Z_w(x) = \sum_y \exp(w^T F(y,x))$$



CRF的矩阵形式

□ 引入特殊的起点、终点标记：

■ $y_0 = \text{start}$, $y_{n+1} = \text{stop}$

■ start, stop也是属于标记空间的某两个值

□ 定义m阶矩阵(m是标记 y_i 取值的个数) $M_i(x) = [M_i(y_{i-1}, y_i | x)]$

□ $M_i(x)$ 的元素是状态序列的转移概率，它的第r行第s列表示当前状态是r时，转移到状态s的概率。

■ 事实上，这里的状态r即为 y_{i-1} ，下一个状态即 y_i

□ 根据CRF的简化记号，矩阵 M_i 的元素为：

$$M_i(y_{i-1}, y_i | x) = \exp(W_i(y_{i-1}, y_i | x))$$

□ 其中，

$$W_i(y_{i-1}, y_i | x) = \sum_{k=1}^K w_k f_k(y_{i-1}, y_i, x, i)$$



CRF的矩阵乘积和条件概率

- 条件概率 $P(y|x)$ 可以写成如上这些 $n+1$ 个状态转移矩阵中相应状态 $y_1y_2\ldots y_n$ 对应的元素的乘积：

$$P_w(y|x) = \frac{1}{Z_w(x)} \prod_{i=1}^{n+1} M_i(y_{i-1}, y_i | x)$$

- 其中， $Z(x)$ 是归一化因子，对上式两边求关于 y 的积分(加和)，得：

$$Z_w(x) = (M_1(x)M_2(x)\cdots M_{n+1}(x))_{start, stop}$$

- $y_0=start$, $y_{n+1}=stop$ 表示开始和终止状态，是以 $start$ 为起点 $stop$ 为终点通过状态 $y_1y_2\ldots y_n$ 的所有路径的非规范化概率之和，所以，恰好是概率转移矩阵连乘 $n+1$ 次后得到的新矩阵 $(start, end)$ 位置的元素值。



CRF的三个问题

- CRF的概率计算问题
 - 前向后向算法
- CRF的参数学习问题
 - IIS: 改进的迭代尺度算法
- CRF的预测算法
 - Viterbi算法



CRF的概率计算问题

- 给定条件随机场 $P(Y|X)$ ，输入序列 x 和输出序列 y ，计算：
 - 条件概率 $P(Y_i=y_i|x)$
 - 条件联合概率 $P(Y_{i-1}=y_{i-1}, Y_i=y_i|x)$
 - 手段：前向后向算法



前向向量

□ $\alpha_i(y_i|x)$: 在位置 i 的标记是 y_i 并且到位置 i 的前部分标记序列的非规范化概率。

■ y_i 可取的值有 m 个: $\alpha_i(y_i|x)$ 是 m 维列向量

$$\alpha_0(y|x) = \begin{cases} 1, & y = start \\ 0, & otherwise \end{cases}$$

$$\alpha_i^T(y_i|x) = \alpha_{i-1}^T(y_{i-1}|x) M_i(y_{i-1}, y_i|x), \quad i = 1, 2, \dots, n+1$$

$$\alpha_i^T(x) = \alpha_{i-1}^T(x) M_i(x)$$



后向向量

- $\beta_i(y_i|x)$: 在位置 i 的标记是 y_i 并且从 $i+1$ 到 n 的后部分标记序列的非规范化概率。
- y_i 可取的值有 m 个: $\beta_i(y_i|x)$ 是 m 维列向量

$$\beta_{n+1}(y_{n+1}|x) = \begin{cases} 1 & y_{n+1} = stop \\ 0 & y_{n+1} \neq stop \end{cases}$$

$$\beta_i(y_i|x) = M_i(y_i, y_{i+1}|x) \beta_{i+1}(y_{i+1}|x), \quad i = 1, 2, \dots, n$$

$$\beta_i(x) = M_{i+1}(x) \beta_{i+1}(x)$$



归一化因子

□ 归一化因子 $Z(x)$:

$$Z(x) = \alpha_n^T(x) \cdot 1 = 1^T \cdot \beta_1(x)$$



概率计算

□ 根据非规范化的前向、后向概率，条件概率 $P(Y_i=y_i|x)$ ，联合条件概率 $P(Y_{i-1}=y_{i-1}, Y_i=y_i|x)$ 分别为：

$$P(Y_i = y_i|x) = \frac{\alpha_i^T(y_i|x)\beta_i(y_i|x)}{Z(x)}$$

$$P(Y_{i-1} = y_{i-1}, Y_i = y_i|x) = \frac{\alpha_{i-1}^T(y_{i-1}|x)M_i(y_{i-1}, y_i|x)\beta_i(y_i|x)}{Z(x)}$$



CRF的参数学习问题

□ 根据训练数据集 (x,y) ，可以求出经验概率分布 $P(x,y)$

■ 大数定理：用频率估计概率

□ 使用极大似然估计给出目标函数：

$$\begin{aligned} L(w) &= \log \prod_{x,y} P_w(y|x)^{\tilde{P}(x,y)} = \sum_{x,y} \tilde{P}(x,y) \log P_w(y|x) \\ &= \sum_{x,y} \left[\tilde{P}(x,y) \left(\sum_{k=1}^K w_k f_k(x,y) \right) - \tilde{P}(x,y) \log Z_w(x) \right] \\ &= \left(\sum_{j=1}^N \sum_{k=1}^K w_k f_k(x_j, y_j) \right) - \sum_{j=1}^N \log Z_w(x_j) \end{aligned}$$



改进的迭代尺度算法

- 算法通过计算似然函数该变量的下界，从而给出下界的最优值，迭代进行，不断更新参数 w 。

$$w = (w_1, w_2, \dots, w_K)^T$$

$$\delta = (\delta_1, \delta_2, \dots, \delta_K)^T$$

$$w + \delta = (w_1 + \delta_1, w_2 + \delta_2, \dots, w_K + \delta_K)^T$$



变化率 δ 的函数

□ 经过计算，关于转移特征 t_k 的更新方程为：

$$E_{\tilde{P}}[t_k] = \sum_{x,y} \tilde{P}(x)P(y|x) \left(\sum_{i=1}^{n+1} t_k(y_{i-1}, y_i, x, i) \exp(\delta_k T(x, y)) \right), \quad k = 1, 2, \dots, K_1$$

□ 关于状态特征 s_l 的更新方程为：

$$E_{\tilde{P}}[s_l] = \sum_{x,y} \tilde{P}(x)P(y|x) \left(\sum_{i=1}^n s_l(y_i, x, i) \exp(\delta_{K_1+l} T(x, y)) \right), \quad l = 1, 2, \dots, K_2$$

□ 其中 $T(x, y)$ 为在数据 (x, y) 中出现的所有特征数之和

$$T(x, y) = \sum_{k=1}^K \sum_{i=1}^{n+1} f_k(y_{i-1}, y_i, x, i)$$



参数学习：改进的迭代尺度算法IIS

- 在当前转移特征 t_k 和状态特征 s_1 给定的条件下，求关于未知向量 δ 的式子：

$$E_{\tilde{P}}[t_k] = \sum_{x,y} \tilde{P}(x) P(y|x) \left(\sum_{i=1}^{n+1} t_k(y_{i-1}, y_i, x, i) \exp(\delta_k T(x, y)) \right), \quad k = 1, 2, \dots, K_1$$

- 取所有 $T(x,y)$ 的最大值 S ，并用 S 代替其他 $T(x,y)$ ，则上式可直接给出解析式：
- 其中，

$$\delta_k = \frac{1}{S} \log \frac{E_{\tilde{P}}[t_k]}{E_P[t_k]}$$

$$E_P[t_k] = \sum_x \tilde{P}(x) \left(\sum_{i=1}^{n+1} \sum_{y_{i-1}, y_i} t_k(y_{i-1}, y_i, x, i) \frac{\alpha_{i-1}^T(y_{i-1}|x) M_i(y_{i-1}, y_i|x) \beta_i(y_i|x)}{Z(x)} \right)$$

- 否则，需要使用拟牛顿或L-BFGS等方式计算 δ 。



CRF的预测算法

□ CRF的预测问题，是给定条件随机场 $P(Y|X)$ 和输入序列(观测序列) x ，求条件概率最大的输出序列(标记序列) y^* ，即对观测序列进行标注。

■ Viterbi算法



最优路径的目标函数

□ 根据推导：

$$\begin{aligned} y^* &= \arg \max_y P_w(y | x) \\ &= \arg \max_y \frac{\exp(wF(y, x))}{Z_w(x)} \\ &= \arg \max_y \exp(wF(y, x)) \\ &= \arg \max_y wF(y, x) \end{aligned}$$

□ CFR 的预测问题即非规范化概率最大的最优路径问题。



最优路径的目标函数

□ 其中,

$$w = \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_K \end{pmatrix} \quad F(y, x) = \begin{pmatrix} f_1(y, x) \\ f_2(y, x) \\ \vdots \\ f_K(y, x) \end{pmatrix}$$

$$f_k(y, x) = \sum_{i=1}^n f_k(y_{i-1}, y_i, x, i)$$



最优路径的目标函数

□ 目标函数:

$$\max_y \sum_{i=1}^n w \cdot F_i(y_{i-1}, y_i, x)$$

□ 其中:

$$F_i(y_{i-1}, y_i, x) = \begin{pmatrix} f_1(y_{i-1}, y_i, x, i) \\ f_2(y_{i-1}, y_i, x, i) \\ \vdots \\ f_K(y_{i-1}, y_i, x, i) \end{pmatrix}$$



状态预测：Viterbi算法

□ 定义：位置*i*的各个标记*l*=1,2,...,m的非规范化概率的最大值。

$$\delta_1(l) = w \cdot F_1(y_0 = \text{start}, y_1 = l, x) \quad l = 1, 2, \dots, m$$

$$\delta_i(l) = \max_{1 \leq j \leq m} \{ \delta_{i-1}(j) + w \cdot F_i(y_{i-1} = j, y_i = l, x) \} \quad l = 1, 2, \dots, m$$

$$y_n^* = \arg \max_{1 \leq j \leq m} \delta_n(j)$$



CRF总结

- 条件随机场是给定输入的条件下，关于输出的条件概率分布模型，根据Hammersley-Clifford定理，可以分解成若干关于最大团的非负函数的乘积，因此，常常将其表示为参数化的对数线性模型。
- 线性链条件随机场使用对数线性模型，关注无向图边的转移特征和点的状态特征，并对每个特征函数给出各自的权值。
 - 概率计算常常使用前向-后向算法；
 - 参数学习使用MLE建立目标函数，采用IIS做参数优化；
 - 线性链条件随机场的应用是标注/分类，在给定参数和观测序列(样本)的前提下，使用Viterbi算法进行标记的预测。



参考文献

- ❑ Machine Learning: A Probabilistic Perspective, Kevin P. Murphy, The MIT Press, 2012
- ❑ Conditional Random Fields: An Introduction, Hanna M. Wallach, 2004
- ❑ An Introduction to Conditional Random Fields, Charles Sutton, Andrew McCallum, 2012
- ❑ 统计学习方法, 李航著, 清华大学出版社, 2012年
- ❑ Pattern Recognition and Machine Learning Chapter 13, Bishop M, Springer-Verlag, 2006
- ❑ Radiner L, Juang B. An introduction of hidden markov Models. IEEE ASSP Magazine, January 1986



我们在这里

7 | 七月算法 <http://www.julyedu.com/>

- 视频/课程/社区

- 七月题库APP: Android/iOS

- <http://www.julyapp.com/>

- 微博

- @研究者July

- @七月题库

- @邹博_机器学习

- 微信公众号

- julyedu



感谢大家！

恳请大家批评指正！

